

Ringkasan Revisi Naskah IJOST

Tindak lanjut catatan “kurangan dari DINO-EVA2”

Naskah: “Frozen DINOv3 and Multilingual-E5 Embeddings with CatBoost for Multimodal Triage of Citizen Environmental Reports” — berkas SmartCitty_IJOST_Rev_1.docx (semua perubahan berupa tracked changes).

29 September 2026 · Angka ditulis seperti di naskah (koma pemisah ribuan, titik desimal). pp = percentage points.

1. Ringkasan

- **Semua permintaan dikerjakan.** Tiga analisis yang diminta (kalibrasi, uji berpasangan antar-encoder, selective prediction) kini ada di Subbab 3.4 baru, lengkap dengan Tabel 5–7 dan Gambar 5–6.
- **Data per-sampel asli tidak tersedia.** Cache embedding dan checkpoint asli hilang bersama pod RunPod, dan snapshot 61,773 pasangan tidak bisa diambil lagi. Karena itu analisis per-sampel memakai run replikasi pipeline yang sama pada snapshot yang tersisa (37,503 pasangan; test $n = 5,626$). Subbab ini diberi label jelas sebagai replikasi; semua angka utama naskah tetap dari run asli.
- **Hasil utama:** Di checkpoint yang sama, rata-rata PGS menurunkan akurasi (-0.36 pp; McNemar $p = 0.0119$) dan memperburuk kalibrasi (ECE 0.0379 vs 0.0271). Ketiga encoder tidak berbeda signifikan setelah koreksi Holm. Untuk menunda laporan yang meragukan, max-probability biasa (AUROC 0.8041) jauh lebih baik daripada sinyal epistemik PGS (AUROC 0.6447).
- **Klaim naskah disesuaikan.** Naskah tidak lagi menyebut PGS sebagai metode kalibrasi untuk model penelitian ini, dan klaim bahwa nilainya ada pada sinyal ketidakpastian diperlunak. Frasa “calibrated via PGS” di 1.1 sengaja dipertahankan karena mendeskripsikan studi Hanif et al. (2026). Klaim yang tetap didukung dikuatkan dengan uji berpasangan.
- **Terverifikasi.** Naskah diperiksa oleh dua putaran review adversarial multi-agen. Putaran 1 menghasilkan 58 temuan; 42 diterima dan diterapkan, 16 ditolak setelah diverifikasi ulang. Putaran 2 menghasilkan 18 temuan, semuanya diterapkan. Ringkasan ini juga di-fact-check terhadap sumber datanya. Kode, tes otomatis, dan Dockerfile siap di repositori.

2. Catatan yang diminta dan statusnya

Permintaan dalam catatan	Dikerjakan di naskah	Status
ECE dan reliability diagram, dengan dan tanpa PGS	Subbab 3.4, Tabel 5, Gambar 5; metode di 2.6	Selesai (replikasi)
Uji McNemar dan paired bootstrap antar-encoder (DINOv3-L, EVA-02-L, DINOv2-L)	Subbab 3.4, Tabel 6	Selesai (replikasi)
Selective prediction: kurva akurasi–cakupan, AUROC ketidakpastian vs. kesalahan	Subbab 3.4, Tabel 7, Gambar 6	Selesai (replikasi)
Ketidakpastian epistemik per sampel untuk versi PGS	Kolom MI, entropi, dan SD antar-anggota di ekspor per-sampel	Selesai
Uji klaim “nilai PGS ada pada sinyal ketidakpastian, bukan akurasi”	Subbab 3.4 (paragraf penutup), 3.3, Kesimpulan, 5.1	Selesai; klaim dikualifikasi
Skrip Python siap jalan untuk ekspor CSV per model	export_per_sample_predictions.py + folder replication/	Selesai

3. Kendala dan keputusan

Catatan tersebut berasumsi cache embedding dan checkpoint CatBoost di RunPod masih ada, sehingga cukup mengeksport probabilitas per sampel tanpa melatih ulang. Ternyata pod itu sudah terhapus. Mirror Drive yang tersisa (86,888 record mentah) bukan snapshot yang sama dengan skripsi, sehingga test set 9,266 sampel

tidak bisa direkonstruksi. Dari tiga pilihan (mengganti semua angka naskah, membatalkan subbab baru, atau replikasi berlabel), penulis memilih replikasi berlabel. Angka utama naskah tetap dari run asli; Subbab 3.4 memakai run ulang pipeline yang sama dan menampilkan angka run asli berdampingan sebagai pembanding. Selain itu, sebagian klaim run asli bisa diuji tanpa data per-sampel. Uji McNemar hanya bergantung pada pasangan diskordan, sehingga p-value kasus terburuk bisa dihitung dari akurasi yang sudah dilaporkan. Hasil ini masuk ke Subbab 3.2 dan 3.3 serta grup D Tabel 1.

4. Rancangan run replikasi

Aspek	Run asli (naskah)	Run replikasi (Subbab 3.4)
Data	88,302 record → 61,773 pasangan	86,888 record → 37,647 setelah dedup (49,241 duplikat, 56.7%) → 37,503 dengan gambar tersedia
Periode laporan	tidak dilaporkan	1 Februari – 2 Desember 2023 (WIB)
Split (seed 42, 70/15/15)	43,241 / 9,266 / 9,266	26,251 / 5,626 / 5,626
Encoder	DINOv3-L (HF), EVA-02-L, DINOv2-L, Hiera-L; 4 encoder teks	DINOv3-L (port timm; preprocessing bit-identik dengan processor HF), EVA-02-L, DINOv2-L; mE5-L
Kepala CatBoost	baseline + PGS untuk 16 pasangan	baseline + PGS untuk DINOv3-L; PGS saja untuk EVA-02-L dan DINOv2-L
Jumlah pohon DINOv3-L	1,500 / 2,989	1,494 / 2,289
Perangkat	RunPod (GPU dan CPU)	RTX 3070 Ti Laptop (embedding), CPU (CatBoost; PGS hanya didukung CPU)

Logika pembersihan, pemetaan label, split, fusi, dan parameter CatBoost disalin dari notebook 02–08. Perbedaannya ada pada snapshot data, sumber bobot DINOv3, cakupan (tiga encoder gambar dengan mE5-L; baseline hanya untuk DINOv3-L), perangkat, dan versi pustaka (catboost 1.2.10, transformers 5.11, timm 1.0.27).

5. Hasil

5.1 Kinerja top-1: replikasi vs. run asli

Konfigurasi (checkpoint, inferensi)	Akurasi replikasi	Akurasi asli	Macro-F1 replikasi	Macro-F1 asli
DINOv3-L + mE5-L, baseline, argmax	0.8027	0.7996	0.7694	0.7684
DINOv3-L + mE5-L, baseline, PGS-averaged	0.7972	0.7914	0.7632	0.7600
DINOv3-L + mE5-L, PGS, argmax (served)	0.8102	0.8116	0.7752	0.7793
DINOv3-L + mE5-L, PGS, PGS-averaged	0.8066	0.8074	0.7721	0.7747
EVA-02-L + mE5-L, PGS, PGS-averaged	0.8116	—	0.7781	0.7747
DINOv2-L + mE5-L, PGS, PGS-averaged	0.8047	—	0.7730	0.7736


Angka run asli dari Tabel 1–4 dan Gambar 4 naskah. Replikasi memakai data dan test set yang berbeda, sehingga yang dibandingkan adalah polanya, bukan angka persisnya.

5.2 Kalibrasi (Tabel 5, Gambar 5)

Checkpoint, inferensi	Akurasi	Rata-rata confidence	ECE [95% CI]	Brier	NLL
Baseline, argmax	0.8027	0.7614	0.0441 [0.0354, 0.0540]	0.2939	0.6076
Baseline, PGS-averaged	0.7972	0.7467	0.0517 [0.0430, 0.0614]	0.3026	0.6284
PGS, argmax (served path)	0.8102	0.7835	0.0271 [0.0214, 0.0381]	0.2822	0.5779
PGS, PGS-averaged	0.8066	0.7689	0.0379 [0.0319, 0.0493]	0.2900	0.5965

PGS, argmax + temperature scaling	0.8102	0.8100	0.0204 [0.0164, 0.0314]	0.2807	0.5734
-----------------------------------	--------	--------	-------------------------	--------	--------

Uji berpasangan pada sampel yang sama menunjukkan bahwa PGS-averaged memperburuk kalibrasi dibanding argmax: $\Delta\text{ECE} = +0.0107$ [0.0054, 0.0163], $\Delta\text{Brier} = +0.0079$ [0.0071, 0.0087], $\Delta\text{NLL} = +0.0185$ [0.0169, 0.0200]. Temperature scaling ($T = 0.90$) menurunkan ECE, tetapi tidak signifikan ($\Delta\text{ECE} = -0.0068$ [-0.0152, 0.0039]); Brier dan NLL turun signifikan. Kedua jalur inferensi sedikit underconfident.



Gambar 5 naskah — reliability diagram checkpoint PGS: (a) argmax (jalur yang di-serve), (b) PGS-averaged, (c) argmax + temperature scaling.

5.3 Uji berpasangan (Tabel 6)

Perbandingan (A vs. B)	$\Delta\text{Akurasi}$, pp [CI]	$\Delta\text{Macro-F1}$, pp [CI]	b / c	McNemar p	Holm p
DINOv3-L vs. EVA-02-L	-0.50 [-1.07, 0.14]	-0.60 [-1.33, 0.18]	144 / 172	0.129	0.257
DINOv3-L vs. DINOv2-L	+0.20 [-0.44, 0.84]	-0.08 [-0.81, 0.64]	159 / 148	0.568	0.568
EVA-02-L vs. DINOv2-L	+0.69 [0.05, 1.28]	+0.52 [-0.28, 1.27]	169 / 130	0.0278	0.0834
PGS-averaged vs. argmax (checkpoint PGS)	-0.36 [-0.62, -0.09]	-0.31 [-0.69, 0.06]	19 / 39	0.0119	0.0239
PGS-averaged vs. baseline argmax (naif)	+0.39 [-0.11, 0.92]	+0.27 [-0.35, 0.93]	127 / 105	0.168	0.168


McNemar menguji ketepatan top-1 (akurasi); interval $\Delta\text{Akurasi}$ dan $\Delta\text{Macro-F1}$ berasal dari paired bootstrap 2,000 resample. Holm dihitung per keluarga: tiga perbandingan encoder dan dua perbandingan mode inferensi.

5.4 Selective prediction (Tabel 7, Gambar 6)

Skor ketidakpastian	AUROC [95% CI]	AURC $\times 100$	Akurasi @80% cakupan	Cakupan @90% akurasi
1 – max p, argmax (served)	0.8041 [0.7902, 0.8175]	6.78	0.8809	0.724
1 – max p, PGS-averaged	0.7985 [0.7849, 0.8122]	7.12	0.8745	0.710
Entropi prediktif (total)	0.7810 [0.7672, 0.7952]	7.52	0.8649	0.679
Entropi harapan (aleatorik)	0.7811 [0.7673, 0.7954]	7.52	0.8647	0.679
Mutual information (epistemik)	0.6447 [0.6273, 0.6616]	11.70	0.8258	0.424
SD antar-anggota (skor lama)	0.6959 [0.6800, 0.7114]	9.89	0.8345	0.527

Selisih berpasangan: $\text{MI} - \text{max p (served)} = -0.1594$ [-0.1749, -0.1444]; $\text{max p PGS} - \text{max p served} = -0.0056$ [-0.0105, -0.0009].

Menunda 20% laporan paling ragu menaikkan akurasi laporan yang dirutekan otomatis dari 0.8102 ke 0.8809.



Gambar 6 naskah — (a) akurasi laporan yang dirutekan otomatis terhadap cakupan; (b) sebaran mutual information untuk prediksi benar dan salah.

5.5 Uji berpasangan pada run asli (batas McNemar kasus terburuk)

Perbandingan (angka naskah)	p kasus terburuk	Kesimpulan	Letak di naskah
Fusi vs. teks saja, kepala PGS (Tabel 3)	≤ 0.003	signifikan	3.2; Tabel 1 grup D; Kesimpulan
Fusi vs. teks saja, tanpa PGS (Tabel 3)	≤ 0.031	signifikan	3.2; Tabel 1 grup D
PGS-averaged vs. argmax, checkpoint PGS (≤ 130 beda top-1)	$\leq 7.6 \times 10^{-4}$	PGS menurunkan akurasi	3.3; Tabel 1; Kesimpulan; 5.1
Selisih naif (checkpoint berbeda; +0.63 pp macro-F1, +0.78 pp akurasi)	≤ 0.25 (batas atas, akurasi top-1)	tidak dapat disimpulkan	3.3; Kesimpulan

Dihitung oleh `mcnemar_bounds.py` hanya dari akurasi dan jumlah beda top-1 (130) yang tercetak di naskah ($n = 9,266$). McNemar menguji akurasi top-1, bukan macro-F1.

6. Dampak pada klaim naskah

Klaim di naskah	Hasil replikasi	Tindakan
PGS menurunkan akurasi pada jumlah pohon tetap	Didukung (-0.36 pp, $p = 0.0119$)	Dikuatkan dengan batas McNemar (run asli) dan uji replikasi
Selisih naif +0.63 pp tidak signifikan	Replikasi: +0.39 pp akurasi (McNemar $p = 0.168$); +0.27 pp macro-F1 $[-0.35, 0.93]$	Diluruskan: di run asli argumen tumpang-tindih interval tidak sah; hanya replikasi yang teruji berpasangan
DINOv3-L dan EVA-02-L setara	Tidak berbeda signifikan (Holm $p = 0.257$); EVA-02-L unggul tipis	Ditambah catatan bahwa tidak signifikan $\neq$ setara
PGS mengkalibrasi probabilitas	Tidak didukung: PGS memperburuk ECE, Brier, NLL	Sebutan PGS sebagai kalibrasi dihapus dari Abstrak, 1.1, 1.2, 2.3, 2.4, 3.3, 5.1, dan Keterbatasan; frasa di 1.1 yang mendeskripsikan Hanif et al. (2026) dipertahankan
Nilai PGS ada pada sinyal ketidakpastian	Dikualifikasi: MI AUROC 0.6447 < max p 0.8041	Diubah menjadi “if anywhere”; max-probability dinyatakan sebagai sinyal penundaan yang lebih baik

7. Daftar perubahan naskah per bagian

Bagian	Perubahan (semua tracked changes)
Abstrak	“calibrated via PGS” → “with PGS virtual ensembles”; satu kalimat hasil uji berpasangan dan replikasi.
1.1, 1.2	Istilah “PGS calibration” diganti “PGS mechanism” / “head that uses PGS”.
2.3	Koreksi: pooling linear (bukan log-linear); dekomposisi ketidakpastian dilengkapi (aleatorik = rata-rata entropi per anggota; total = entropi prediktif); 0.00339 = SD antar-anggota, bukan MI; Malinin et al. (2021); “native probability calibration” → “native posterior sampling”; early stopping pada log-loss validasi (patience 50/200), bukan macro-F1; hilangnya PGS di ONNX dirujuk.
2.4	Tanpa istilah “calibration”; bootstrap disebut bukan uji berpasangan dan dilengkapi McNemar serta replikasi.
2.6	Paragraf metode baru: rancangan replikasi, ECE/Brier/NLL, temperature scaling, McNemar + paired bootstrap + Holm, batas McNemar kasus terburuk, AURC/AUROC, dekomposisi ketidakpastian PGS.
Pengantar Bab 3, Tabel 1	Pengecualian untuk Subbab 3.4 (n = 5,626); grup D baru (5 baris), grup E–G direlabel, catatan tabel membedakan run asli dan replikasi, singkatan ditambah.
3.2, 3.3	Batas McNemar (fusi $p \leq 0.003$; PGS $p \leq 7.6 \times 10^{-4}$); argumen selisih naif diluruskan; nilai PGS menjadi “if anywhere”; rujukan ke uji replikasi.
3.4 (baru)	Kalibrasi, uji berpasangan, dan selective prediction: 5 paragraf, Tabel 5–7, Gambar 5–6.
3.5–3.9	Penomoran ulang (Subbab 3.5–3.9, Tabel 8–13, Gambar 7–8) beserta semua rujukan silang (mis. 2.5 “Section 3.4” → 3.5; 3.1 “Section 3.7” → 3.8; rujukan ke “Section 3.9” yang tidak ada → “Acknowledged Limitations”); typo “Export party” → “parity”; kalimat baru soal dampak hilangnya PGS di ONNX; pelajaran praktis ke-4; baris Uncertainty di Tabel 13.
Kesimpulan	Batas McNemar, status selisih naif, ringkasan hasil replikasi, rencana lanjutan disesuaikan.
Bagian 5, 6.2, 6.3	Pengantar Bagian 5 menandai klaim yang berasal dari replikasi; klaim kontribusi 5.1 disesuaikan (termasuk aspek ke-4 yang sebelumnya hilang); catatan saran diberi status beserta hasilnya.
Keterbatasan	(ii) diperbaiki; (vi) baru: replikasi pada snapshot lain, port timm DINOv3, satu seed pelatihan.
Referensi	+6: Dietterich (1998), Geifman & El-Yaniv (2017), Guo et al. (2017), Hendrycks & Gimpel (2017), Holm (1979), Malinin et al. (2021).

8. Hal yang perlu diperiksa penulis

- **Inkonsistensi 0.8073/0.8074.** Akurasi headline tertulis 0.8074 (Tabel 1, 3.1, Tabel 3, pembuka 3.4, dan dua kali di Bagian 5) tetapi 0.8073 di Tabel 2, 4, dan 8. Bedanya bisa satu sampel (7,480 vs. 7,481 dari 9,266) atau hanya pembulatan ($7,481/9,266 = 0.80736$: dibulatkan 0.8074, dipotong 0.8073). Seragamkan berdasarkan log eksperimen.
- **Opsional, istilah kesetaraan encoder.** Frasa “indistinguishable on accuracy” (3.2) dan “perform near-identically” (5.1) benar untuk run asli (macro-F1 sama persis), tetapi pertimbangkan menambahkan bahwa uji berpasangan pada replikasi tidak menemukan selisih signifikan, dan itu tidak sama dengan setara.
- **Figure 1 hilang.** Teks merujuk Figure 1 (kerangka penelitian), tetapi gambarnya tidak ada.
- **Template IJOST.** Kata kunci, riwayat artikel, dan hak cipta di kotak ARTICLE INFO masih teks template IJOST.
- **Sebelum submit.** Tinjau tracked changes, pilih Accept All, lalu hapus 6 komentar penjelasan dari Claude.
- **Opsional.** Kalau diinginkan, replikasi bisa diperluas ke kepala teks-saja dan gambar-saja (untuk uji berpasangan fusi) atau ke beberapa seed pelatihan.

9. Berkas dan reproduksibilitas

- **Naskah:** SmartCitty_IJOST_Rev_1.docx (naskah dengan tracked changes), serta PDF versi tracked dan versi bersih.
- **Kode:** folder repositori semogaLancarQ1nyaPakHaris- berisi skrip ekspor, analisis, pengisian naskah, replikasi (run_pipeline.py dapat dilanjutkan dari tahap terakhir), tes otomatis (lulus di Windows dan di Docker/Linux), Dockerfile, dan README. Data, model, dan naskah .docx tidak disertakan.
- **Jejak angka:** angka di Subbab 3.4 berasal dari results.json, calibration_paired.json (selisih berpasangan ECE/Brier/NLL dan temperature scaling), dan replication_summary.json (jumlah data dan pohon). Semuanya dihitung dari prediksi per-sampel dan log run replikasi; angka run asli pembandingan dikutip dari naskah. Kata interpretasi dipilih dari interval kepercayaan. Naskah dibangun ulang dari backup asli dengan dua perintah (tools/build_revised_docx.py lalu fill_manuscript.py; folder tools/ tidak ikut di repositori).